

研究方向

我的研究聚焦于检索增强生成 (RAG) 与大模型智能体训练，涵盖两个核心方向：(1) **RAG & Deep Search**——构建可靠、自适应、具备拒答意识的检索增强系统，使模型知道何时检索、检索什么、如何检索以及何时停止，迈向自主深度研究智能体；(2) **LLM Agent Training**——通过强化学习与后训练赋予大模型智能体多轮探索、工具调用、结构化推理、细粒度 credit assignment 及环境反馈学习等能力。目前在蚂蚁集团机器智能部门担任蚂蚁星实习生。博士期间已发表 7 篇一作/共同一作顶会/顶刊论文 (CCF-A / TH-CPL A 6 篇、CCF-B 1 篇)，另有 2 篇共同一作在投论文 (AAAI 2027 × 2)。

教育背景

中国科学技术大学

合肥, 中国

控制科学与工程 在读博士 (中国科学院自动化研究所联合培养)

2022 – 2027 (预计)

– 中国科学院自动化研究所模式识别国家重点实验室 (NLPR)

– 导师: 王亮教授 (IEEE Fellow)、刘强副研究员

– 荣誉: 国家奖学金 (2024)、中国科学技术大学一等学业奖学金 (2022–2025, 连续三年)

上海交通大学

上海, 中国

计算机科学与技术 工学学士

2018 – 2022

– 荣誉: 国家励志奖学金 (2019–2022)、上海交通大学学业奖学金

论文发表

► 一作论文

[1] KBQA-R1: Reinforcing Large Language Models for Knowledge Base Question Answering

Xin Sun, Zhongqi Chen, Xing Zheng, Qiang Liu, Shu Wu, Bowen Song, Zilei Wang, Weiqiang Wang, Liang Wang

ICML 2026 (CCF-A) 公众号解读 构建面向知识库问答的自主探索 Agent, 通过 Agent RL 学习基于环境反馈的知识检索与推理策略; 提出 RRS 解决 RL 冷启动, RRGc 缓解稀疏奖励问题, 在大幅提升回答准确率的同时推理效率较 MCTS 方法提升 26 倍。

[2] GAPD: Gold-Action Policy Distillation for Agentic Reinforcement Learning in Knowledge Base Question Answering

Xin Sun, Zhongqi Chen, Xing Zheng, Qiang Liu, Shu Wu, Bowen Song, Zilei Wang, Weiqiang Wang, Liang Wang

EMNLP 2026, Findings (TH-CPL A) 面向 agentic KBQA 中 outcome-only RL 的稀疏监督问题, 提出 gold-action-conditioned self-teacher 与 Entity-Anchor Matching, 将 gold action 转化为安全对齐的 token-level policy guidance, 在保持原始 GRPO 目标的同时提升训练密度与稳定性。

[3] Divide-Then-Align: Honest Alignment based on the Knowledge Boundary of RAG

Xin Sun, Jianan Xie, Zhongqi Chen, Qiang Liu, Shu Wu, Yuehe Chen, Bowen Song, Zilei Wang, Weiqiang Wang, Liang Wang

ACL 2025, Main Conference (CCF-A) 公众号解读 定义 RAG 的四象限知识边界 (参数知识 ∪ 检索知识), 为各象限构造差异化偏好数据, 通过 DPO+SFT+ 分类辅助多目标训练实现诚实对齐, 使模型学会在知识不足时拒答。

[4] **EviSD: Evidence-Conditioned Self-Distillation for Search-Augmented Agents**

Jianan Xie*, **Xin Sun***, Zhongqi Chen, Xing Zheng, Shu Wu, Bowen Song, Liang Wang

AAAI 2027 投稿中 arXiv:2608.01359 * 共同第一作者 提出 evidence-conditioned self-distillation, 以 supporting evidence 与 golden answer 作为 action-level credit assignment 的特权信息; 在 7 个 QA benchmark 上取得最高 macro-average EM, 且仅调制 6.7%–15.1% 的响应 token。

[5] **HopRefusalBench: Diagnosing Refusal Failures in Search-Augmented Agents for Multi-Hop Reasoning**

Jianan Xie*, **Xin Sun***, Zhongqi Chen, Xing Zheng, Qiang Liu, Bowen Song

AAAI 2027 投稿中 arXiv:2608.01358 * 共同第一作者 构建 889 题多跳拒答评测基准, 交叉覆盖 3 类不可回答原因与 root/middle/terminal 拓扑; 评测 10 个前沿模型, 最优模型的 target-aware correct halting rate 仅 42.9%, 暴露出持续的幻觉回答与搜索预算耗尽问题。

[6] **Predict the Retrieval! Test Time Adaptation for Retrieval Augmented Generation**

Xin Sun, Zhongqi Chen, Qiang Liu, Shu Wu, Bowen Song, Weiqiang Wang, Zilei Wang, Liang Wang

ICASSP 2026 (CCF-B) 将检索文档拆分为 prefix-suffix 对构造自监督目标, 在推理时动态更新模型参数以适应目标领域, 无需标注数据即可显著提升 RAG 在专业领域的性能。

[7] **DIVE: Subgraph Disagreement for Graph Out-of-Distribution Generalization**

Xin Sun, Liang Wang, Qiang Liu, Shu Wu, Zilei Wang, Liang Wang

KDD 2024 (CCF-A) 通过子图不一致性学习环境不变的图表征, 解决图神经网络在分布外数据上的泛化问题。

[8] **Noise-Robust Semi-Supervised Learning for Distant Supervision Relation Extraction**

Xin Sun, Qiang Liu, Shu Wu, Zilei Wang, Liang Wang

EMNLP 2023, Findings (TH-CPL A) 利用噪声鲁棒的半监督学习方法改进远程监督关系抽取中的噪声标签问题。

[9] **Uncertainty Calibration for Counterfactual Propensity Estimation in Recommendation**

Wenbo Hu*, **Xin Sun*** (学生第一作者), Qiang Liu, Liang Wang

IEEE TKDE (CCF-A, SCI Q1) 通过不确定性校准改进反事实倾向估计, 提升推荐系统转化率预估的准确性与鲁棒性。

► 合作论文

[10] **ToolWeaver: Weaving Collaborative Semantics for Scalable Tool Use in Large Language Models**

Bowen Fang, Qiang Liu, Yesheng Liu, Jiabing Yang, **Xin Sun**, Shu Wu, Baole Wei, Liang Wang

ICLR 2026 (CAAI-A) 通过协作语义编织实现 LLM 面对大规模工具集时的可扩展工具选择与组合。

[11] **Multimodal Adaptive Retrieval Augmented Generation through Internal Representation Learning**

Ruoshuang Du, **Xin Sun**, Qiang Liu, Bowen Song, Zhongqi Chen, Weiqiang Wang, Liang Wang

IJCNN 2026 (CCF-C) 通过内部表征学习实现多模态场景下的自适应检索增强生成。

[12] **Pin-Tuning: Parameter-Efficient In-Context Tuning for Few-shot Molecular Property Prediction**

Liang Wang, Qiang Liu, Shaozhen Liu, **Xin Sun**, Shu Wu, Liang Wang

NeurIPS 2024 (CCF-A) 面向小样本分子属性预测的参数高效上下文微调方法。

[13] **GSLB: The Graph Structure Learning Benchmark**

Zhixun Li, Liang Wang, **Xin Sun**, Yifan Luo, Yanqiao Zhu, Dingshuo Chen, Yingtao Luo, Xiangxin Zhou, Qiang Liu, Shu Wu, Liang Wang, Jeffrey Xu Yu
NeurIPS 2023 (CCF-A) 首个综合性图结构学习评测基准，集成 16 种 GSL 算法和 20 种图数据集。

实习经历

- 蚂蚁集团杭州, 中国
- 机器智能部门 – 蚂蚁星实习生 (2026.05 起)2024.11 – 至今
- 构建可信 RAG (Trustworthy RAG) 体系: 主导完成多项检索增强生成相关工作, 包括 RAG 可信对齐 (ACL 2025)、多模态自适应 RAG (IJCNN 2026)、RAG 测试时自适应 (ICASSP 2026)、知识库问答 Agent 强化学习 KBQA-R1 (ICML 2026)、搜索智能体细粒度 credit assignment 与多跳拒答可靠性评测 (AAAI 2027 投稿中) 等
 - **MOSA Harness**: 设计融合技能先验、多会话管理与跨会话记忆的自适应多轮攻击框架; 在 Train-free 场景下, 对 Qwen3.5-122B 的 HarmBench 攻击成功率 ASR@3 达到 **70.5%**, 较 Crescendo 提升 **11.0** 个百分点; 进一步基于 GRPO 后训练 27B 攻击模型, 仅在 Qwen3.5-122B 上进行交互训练; 双语模型在 HarmBench 四个 Victim 上的宏平均 ASR@3 达到 **97.4%**, 较同规模 Train-free 提升 **37.5** 个百分点, 在 GLM、Kimi、Ling 上达到 **97.0%–98.5%**
- 字节跳动北京, 中国
- AML – 机器学习工程师实习生2022.02 – 2022.08
- 参与多变量时间序列自动机器学习平台的开发
 - 推荐系统因果推断研究: 提出反事实倾向估计的不确定性校准方法, 发表于 IEEE TKDE (CCF-A)

兴趣爱好

羽毛球 (自评三级) 滑雪 (愚昧之巅) 足球 (巴萨死忠) 桌游 (卡坦岛、宝石、阿瓦隆、花砖、Poker...)

学术服务

会议审稿人: ICML 2026, NeurIPS 2025, ACL 2025, EMNLP 2025, KDD 2024